

Statistical Learning Project

Aircraft Price Prediction: Data Preparation & Linear Models

Amin Borqal

Statistical Learning Course

15 giugno 2025

Agenda

Obiettivo del Progetto

Dataset: Aircraft Price Prediction

- **Fonte:** Kaggle Aircraft Price Dataset
- **Obiettivo:** Predire il prezzo degli aeromobili
- **Target:** price (variabile continua)
- **Dimensioni:** 507 osservazioni, 16 variabili

Approccio Metodologico

- 1 Data Preparation & Feature Engineering
- 2 Exploratory Data Analysis
- 3 Linear Models Implementation
- 4 Model Validation & Cross-Validation

Variabili Numeriche:

- engine_power (shp)
- max_speed (knots)
- cruise_speed (knots)
- fuel_tank (gallons)
- range (nmi)
- empty_weight (lbs)

Variabili Categorie:

- model_name
- engine_type

Target:

- price (USD)
- Range: \$1M - \$5M+

Gestione Dati Mancanti

- **Soglia eliminazione:** 30% di valori mancanti
- **Strategia:** Rimozione righe con missing values
- **Risultato:** Dataset pulito senza valori nulli

Problemi Identificati

- **Skewness elevata** nelle variabili numeriche
- **Distribuzione asimmetrica** del target
- **Scala molto diversa** tra le variabili

Log Transformation

Variabili Trasformate

Features con alta skewness: 2

- fuel_tank
- engine_power
- landing_distance
- empty_weight
- range
- wing_span
- max_speed
- cruise_speed

Target Transformation

$\log(\text{price}) \rightarrow$ Distribuzione più normale

Benefici della Log-Transformation

Prima della trasformazione:

- Distribuzione fortemente asimmetrica
- Code lunghe (outliers)
- Eteroschedasticità
- Problemi con assunti OLS

Dopo la trasformazione:

- Distribuzione quasi normale
- Riduzione outliers
- Varianza più costante
- Interpretazione percentuale

Formula di Interpretazione

β_i in $\log(y) = \beta_0 + \beta_i x_i \Rightarrow$ **variazione % di y per unità di x_i**

Modello Completo

$$\log(\text{price}) = \beta_0 + \sum_{i=1}^{13} \beta_i X_i + \epsilon$$

Performance Metrics:

- $R^2 = 0.865$ (86.5%)
- R^2 aggiustato = 0.861
- RMSE (log) = 0.151
- RMSE (USD) 382,447

Significatività:

- **10 variabili** significative ($p \leq 0.05$)
- **4 variabili** non significative
- F-statistic = 243.1 ($p \leq 0.001$)

Variabili Significantive vs Non Significantive

Significative ($p \leq 0.05$)

- max_speed ($p = 1.5e-06$)
- cruise_speed ($p = 1.7e-22$)
- fuel_tank ($p = 0.020$)
- all_eng_roc ($p = 1.2e-05$)
- takeoff_distance ($p = 0.002$)
- landing_distance ($p = 1.4e-07$)
- empty_weight ($p = 0.006$)
- wing_span ($p = 5.4e-05$)

Non Significantive ($p > 0.05$)

- engine_power ($p = 0.712$)
- stall_speed ($p = 0.360$)
- length ($p = 0.113$)
- range ($p = 0.246$)

Feature Engineering Efficace

La maggior parte delle variabili è significativa dopo la trasformazione!

Analisi della Multicollinearità (VIF)

Variance Inflation Factor

Variabile	VIF
landing_distance	51.6
engine_power	21.7
length	19.2
fuel_tank	18.8
empty_weight	16.7
cruise_speed	10.6
wing_span	6.1
max_speed	5.5

Problema Identificato

VIF ≥ 10 indica forte multicollinearità $\Rightarrow$ Necessarie tecniche di regolarizzazione

Cross Validation: 80-20 Split

Modello Ridotto (5 variabili)

Features: engine_power, max_speed, cruise_speed, fuel_tank, range

Training Set (80%):

- $R^2 = 0.849$
- $n = 405$ osservazioni

Test Set (20%):

- $R^2 = 0.84-0.85$
- $MSE = 0.024$
- $n = 102$ osservazioni

Interpretazione

- **Lieve overfitting** (R^2 diminuisce leggermente)
- **Performance stabile** in validazione
- **Generalizzazione buona** del modello

K-Fold Cross Validation (k=10)

Metodologia

- Dataset diviso in 10 fold
- Ogni fold usato come test set una volta
- Calcolo di metriche aggregate

Risultati Aggregati:

- R^2 medio = 0.84-0.86
- R^2 std = 0.02-0.04
- MSE medio 0.025
- Stabilità elevata

Vantaggi K-Fold

- Uso efficiente dei dati
- Stima più robusta
- Valutazione della variabilità
- Riduce bias da singolo split

Stepforward Regression (Criterio Cp)

Selezione Automatica delle Variabili

- **Algoritmo:** Forward stepwise selection
- **Criterio:** Mallows' Cp statistic
- **Obiettivo:** Minimizzare overfitting e multicollinearità

Formula Mallows' Cp

$$C_p = \frac{RSS_p}{\hat{\sigma}^2} - n + 2p$$

dove RSS_p è la somma dei quadrati dei residui per il modello con p parametri

Benefici

Selezione ottimale del numero di variabili bilanciando bias e varianza

Summary dei Risultati

Performance del Modello

Metrica	Modello Completo	Cross Validation
R^2	0.865	0.84-0.86
RMSE (USD)	382,447	~ 400,000
Variabili	13	5-10
Overfitting	Moderato	Controllato

Eccellente Capacità Predittiva

86.5% della varianza del prezzo spiegata dal modello lineare!

Data Preparation:

- Feature engineering efficace
- Log-transformation appropriata
- Gestione outliers
- Analisi esplorativa completa

Modeling:

- Multiple validation strategies
- Model selection criteria
- Diagnostics completi

Risultati:

- R^2 molto elevato (86.5%)
- Performance stabile in CV
- Interpretabilità mantenuta
- Assumptions verificati

Robustezza:

- K-fold validation
- Multiple train/test splits
- Statistical significance

Problemi Identificati

- **Multicollinearità elevata** ($VIF > 10$ per alcune variabili)
- **Lieve overfitting** nel modello completo
- **Outliers influenti** ancora presenti

Prossimi Passi

- 1 **Regolarizzazione:** Ridge & Lasso Regression
- 2 **Non-Linear Models:** Random Forest, Gradient Boosting
- 3 **Feature Selection:** Advanced techniques
- 4 **Ensemble Methods:** Combine multiple models

Successo del Progetto

- **Obiettivo raggiunto:** Predizione accurata dei prezzi aeromobili
- **Metodologia rigorosa:** From EDA to Model Validation
- **Results significativi:** $R^2 = 86.5\%$ è eccellente per questo dominio
- **Insights di business:** Identificate le features più predittive

Key Takeaways

- 1 La **feature engineering** è cruciale per il successo
- 2 I **modelli lineari** possono essere molto efficaci con i giusti preprocessing
- 3 La **cross-validation** è essenziale per validare le performance
- 4 L'**interpretabilità** rimane un vantaggio chiave dei modelli lineari

Grazie per l'attenzione!

Questions & Discussion

Statistical Learning Project - Aircraft Price Prediction

Amin Borqal