

Analisi Prezzi Aeromobili

Modelli Lineari per la Predizione del Prezzo

Statistical Learning Project

15 giugno 2025

Introduzione al Dataset

- **Dataset:** Prezzi di aeromobili
- **Dimensioni:** 507 osservazioni, 16 variabili
- **Target:** Price (USD)
- **Fonte:** Dati reali di mercato aeronautico

Obiettivo: Predire il prezzo degli aeromobili utilizzando caratteristiche tecniche

Variabili Principali:

- cruise_speed
- max_speed
- fuel_tank
- engine_power
- wing_span
- landing_distance
- empty_weight
- range
- manufacturer
- engine_type
- aircraft_type
- cockpit_type
- fuel_type
- category
- seating_capacity
- **price** (target)

Obiettivo: Costruire un modello lineare multiplo per predire il prezzo

Scatter Plots delle Variabili Numeriche vs Price

- **Correlazioni positive forti:**
 - cruise_speed vs price
 - max_speed vs price
 - fuel_tank vs price
 - engine_power vs price
- **Relazioni non lineari evidenti**
- **Presenza di outliers** nei dati

Analisi delle Distribuzioni:

- **Price**: Fortemente asimmetrica a destra
- **Fuel_tank**: Distribuzione skewed
- **Engine_power**: Asimmetria positiva
- **Landing_distance**: Skewness elevata
- **Empty_weight**: Coda lunga a destra
- **Range**: Distribuzione non normale
- **Wing_span**: Asimmetria moderata

Problema: Le distribuzioni non normali violano le assunzioni del modello lineare

Matrice di Correlazione - Dati Originali

Correlazioni Elevate:

- price - cruise_speed: 0.85
- price - max_speed: 0.82
- price - fuel_tank: 0.89
- price - engine_power: 0.91
- landing_distance - engine_power: 0.95 (**multicollinearità**)

Evidenza di multicollinearità tra alcune variabili

Variabili Trasformate con Log:

- $\text{price} \rightarrow \log(\text{price})$
- $\text{fuel_tank} \rightarrow \log(\text{fuel_tank})$
- $\text{engine_power} \rightarrow \log(\text{engine_power})$
- $\text{landing_distance} \rightarrow \log(\text{landing_distance})$
- $\text{empty_weight} \rightarrow \log(\text{empty_weight})$
- $\text{range} \rightarrow \log(\text{range})$
- $\text{wing_span} \rightarrow \log(\text{wing_span})$

Risultato: Distribuzioni più simmetriche e normali

Matrice di Correlazione - Dati Log-Trasformati

Miglioramenti:

- Correlazioni più lineari
- Riduzione della multicollinearità
- Relazioni più stabili
- Distribuzioni normalizzate

Beneficio: Assunzioni del modello lineare meglio soddisfatte

Modello Lineare Multiplo

Performance del Modello:

- **R^2** : 0.865 (86.5% varianza spiegata)
- **RMSE**: \$382,447
- **Variabili significative**: 10/13 ($p \leq 0.05$)

Cross-Validation:

- Train/Test Split (80-20): $R^2 = 0.849$
- 10-Fold CV: $R^2 = 0.84-0.86$

Variabili Non Significative:

- aircraft_type_Light
- engine_type_Turbo-prop
- manufacturer_Cessna
- manufacturer_Piper

Risultati Principali

- **Modello robusto** con $R^2 = 86.5\%$
- **Cross-validation** conferma stabilità
- **Trasformazione logaritmica** essenziale
- **Multicollinearità** ancora presente

Il modello lineare multiplo è efficace per la predizione dei prezzi degli aeromobili